

ANÁLISIS EXPLORATORIO DE DATOS – ORANGE DATA MINING

Introducción

Para realizar este informe se utilizó **Orange Data Mining** con el objetivo de realizar un análisis exploratorio de la base de datos de hogares. Se estudiaron distintas variables relacionadas con las características económicas y demográficas de los hogares, principalmente **IngresoMensual**, **GastoMensual** y **EdadPromedioHogar**.

Para el análisis se utilizaron herramientas de estadísticas descriptivas, distribuciones, gráficos de dispersión, box plots y correlaciones. Esto permitió estudiar el comportamiento general de las variables, detectar posibles valores atípicos y analizar las relaciones existentes entre ellas.

1. Análisis de tendencia central y dispersión

En primer lugar, se analizaron la media, mediana, desviación estándar y varianza de las principales variables numéricas.

Variable	Media	Mediana	Desv. estándar	Varianza aprox.
IngresoMensual	91.719,9	91.055,7	32.559,8	1.060.140.576
GastoMensual	62.151,3	62.352,3	24.979,4	623.970.424
EdadPromedioHogar	40,19	38	16,56	274,09

Los ingresos y gastos presentan medias y medianas muy cercanas, lo que indica que los datos se encuentran relativamente equilibrados alrededor de sus valores centrales. Sin embargo, las desviaciones estándar son elevadas, mostrando una dispersión considerable entre los distintos hogares.

En cuanto a la edad, el promedio es de aproximadamente 40 años y la mediana de 38 años. Sin embargo, posteriormente se detectaron valores extremos de -5 y 120 años, que no resultan consistentes con un contexto real y podrían corresponder a errores de carga o datos atípicos.

2. Verificación de máximos y mínimos

Los valores mínimos y máximos obtenidos fueron:

Variable	Mínimo	Máximo
IngresoMensual	40.607,4	148.558
GastoMensual	20.623,9	127.691
EdadPromedioHogar	-5	120

Los valores de **IngresoMensual** y **GastoMensual** muestran una amplitud considerable, pero no presentan por sí mismos valores evidentemente imposibles.

El principal problema aparece en **EdadPromedioHogar**. Una edad promedio de -5 años es imposible, por lo que probablemente corresponda a un error de carga. El valor de 120 años también resulta extremadamente elevado, especialmente porque representa la edad promedio de todo un hogar. Por este motivo, ambos valores deberían revisarse y eventualmente corregirse o eliminarse antes de realizar análisis posteriores.

3. Relación entre variables

A través de Scatter Plot se analizó la relación entre la edad promedio de los hogares y sus ingresos y gastos mensuales.

En la relación entre **EdadPromedioHogar** e **IngresoMensual**, los puntos aparecen bastante dispersos y no forman un patrón definido. Por lo tanto, no se observa una tendencia clara que indique que los ingresos aumenten o disminuyan a medida que aumenta la edad promedio.

Algo similar ocurre entre **EdadPromedioHogar** y **GastoMensual**. Los puntos también presentan una dispersión considerable, sin una tendencia clara.

En consecuencia, dentro de esta base de datos, la edad promedio del hogar no parece tener una relación clara con sus ingresos ni con sus gastos mensuales. Además, vuelven a aparecer las edades atípicas de -5 y 120 años, que podrían distorsionar parcialmente los resultados.

4. Análisis de outliers

Mediante Box Plot se buscaron valores atípicos en las variables numéricas.

En **IngresoMensual** y **GastoMensual** se observa una dispersión amplia, pero no aparecen casos tan problemáticos como los encontrados en la variable edad.

En **EdadPromedioHogar**, en cambio, se destacan los valores extremos de -5 y 120 años, muy alejados de la mayor concentración de observaciones, ubicada aproximadamente entre los 30 y 50 años.

El valor de -5 años claramente puede interpretarse como un error de carga, ya que una edad negativa es imposible. El valor de 120 años también resulta extremadamente inusual para representar la edad promedio de un hogar y podría deberse a un error de registro o procesamiento.

Por lo tanto, antes de utilizar definitivamente la base de datos, sería conveniente revisar estos registros y decidir si corresponde corregirlos o eliminarlos.

5. Comparación entre grupos

También se analizó la **EdadPromedioHogar** según el tipo y la zona de vivienda.

Según el tipo de vivienda, los hogares que viven en departamentos presentan una edad promedio de 43,1 años, mientras que quienes viven en casas presentan aproximadamente

36,9 años. Sin embargo, la prueba estadística obtuvo $p = 0,054$. Al ser apenas superior a 0,05, la diferencia no se considera estadísticamente significativa utilizando un nivel de significancia del 5%.

En cambio, según la zona de vivienda, aparecen diferencias más marcadas:

- Urbana: 32,9 años.
- Suburbana: 38,9 años.
- Rural: 49,3 años.

En este caso, el ANOVA obtuvo $p < 0,001$, indicando que existen diferencias estadísticamente significativas entre las zonas. Esto permite identificar un patrón demográfico dentro de la base: los hogares de zonas rurales presentan edades promedio mayores que los suburbanos y urbanos.

6. Análisis de correlaciones

Finalmente, mediante la herramienta Correlations se analizaron las relaciones lineales entre las variables numéricas.

La relación más importante encontrada es entre **IngresoMensual** y **GastoMensual**, que presenta una correlación positiva fuerte de $r = 0,895$. Esto significa que los hogares con mayores ingresos tienden también a presentar mayores gastos mensuales.

Por otro lado, **EdadPromedioHogar** presenta correlaciones prácticamente nulas con:

- **IngresoMensual**: $r = -0,010$.
- **GastoMensual**: $r = -0,051$.

Estos resultados respaldan lo observado previamente en los Scatter Plots: no existe una relación lineal relevante entre la edad promedio del hogar y sus ingresos o gastos. Por lo tanto, la relación más relevante de toda la base es la existente entre ingresos y gastos mensuales.

Conclusión

El análisis exploratorio permitió identificar que los hogares presentan una considerable variabilidad en sus niveles de ingresos y gastos, y que ambas variables están fuertemente relacionadas entre sí: a mayores ingresos, tienden a observarse mayores gastos.

Por otro lado, la **EdadPromedioHogar** no presenta una relación clara con el nivel de ingresos ni con el gasto mensual. Sin embargo, sí se encontraron diferencias según la zona de residencia: los hogares rurales presentan una edad promedio superior a los suburbanos y urbanos.

Finalmente, uno de los principales hallazgos respecto de la calidad de los datos fue la presencia de edades de -5 y 120 años. Estos valores deberían ser revisados antes de continuar con análisis más avanzados, ya que podrían corresponder a errores de carga y afectar los resultados obtenidos.